



هوش مصنوعی

بهار ۱۴۰۴

استاد: محمد مهدی سمیعی پاقلعه، محمدرضا فریدونی

گردآورندگان: امیرعلی رستمی، عسل محمدجعفری

مهلت ارسال: - خرداد

یادگیری ماشین

تمرین پنجم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ روز مشخص شده است.
- توجه داشته باشید که در ترم جاری، تمرین تاخیر مجاز برای ارسال نخواهند داشت.
- در طول ترم امکان ارسال تمرین با سه روز تاخیر وجود دارد و به ازای هر ساعت تاخیر به اندازه سه هشتم درصد از نمره تمرین کسر خواهد شد.
- همچنین توجه داشته باشید که ساعات تاخیر رو به بالا گرد میشوند، برای مثال ارسال تمرین با ده دقیقه تاخیر، معادل یک ساعت تاخیر محاسبه خواهد شد.
- همکاری و همفکری شما در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر کس حتما باید توسط خود او نوشته شده باشد.
- در صورت همفکری و یا استفاده از هر منابع خارج درسی، نام همفکران و آدرس منابع مورد استفاده برای حل سوال مورد نظر را ذکر کنید.
- لطفا تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد.

سوالات نظری (۱۱۰ نمره)

۱. (۲۵ نمره)

مدلی با ساختار شبکه عصبی پرسپترون چندلایه (MLP) در نظر گرفته شده که دارای دو نورون در لایه ورودی، دو نورون در یک لایه میانی (پنهان) و یک نورون خروجی است. لایه پنهان از تابع فعال سازی ReLU و خروجی از تابع هویت (خطی) استفاده می کند. هدف از آموزش، مدل سازی تابعی است که خروجی آن از رابطه زیر تبعیت می کند:

$$y = 2x_1 + 3x_2$$

چهار نمونه ی آموزشی در اختیار داریم که ویژگی ها و خروجی هدف آن ها به صورت زیر مشخص شده اند:

نمونه	x_1	x_2	y
۱	۱	۱	۵
۲	۰	۱	۳
۳	۱	۰	۲
۴	۰	۰	۰

الف) ساختار معماری این شبکه را به صورت شماتیک ترسیم کرده و تعداد پارامترهای قابل یادگیری آن (شامل وزن ها و بایاس ها) را با دلیل مشخص نمایید.

ب) تعریف ریاضی تابع ReLU را ارائه کرده و نمودار آن را در محورهای مناسب رسم کنید. سپس، با مقایسه با تابع سیگموید، مزایا و معایب آن را شرح دهید. در ادامه، خروجی ReLU برای مقدار ورودی برابر با ۲- را مشخص نمایید.

پ) فرض کنید مقادیر اولیه وزن ها و بایاس ها به صورت زیر تعیین شده اند. برای ورودی $x = (1, 1)$ مراحل محاسبه ی pass forward را به صورت مرحله به مرحله انجام دهید و در نهایت، مقدار خطای مدل را با استفاده از تابع خطای میانگین مربعات (MSE) به دست آورید.

• در لایه پنهان:

$$\begin{aligned}w_{11}^{(1)} &= -1, w_{12}^{(1)} = 1 - \\w_{21}^{(1)} &= 1, w_{22}^{(1)} = 2 - \\b_1^{(1)} &= 1, b_2^{(1)} = 0 -\end{aligned}$$

• در لایه خروجی:

$$b^{(2)} = 0, w_1^{(2)} = -1, w_2^{(2)} = 2 -$$

ت) با توجه به خروجی شبکه و خطای به دست آمده، گرادیان وزن های خروجی را نسبت به خطا محاسبه کنید. سپس با استفاده از نرخ یادگیری $\eta = 0.1$ ، مقادیر جدید وزن ها را پس از یک گام به روز رسانی نمایید. همچنین به طور مفهومی بیان کنید چرا انتخاب یک نرخ یادگیری بزرگ می تواند باعث نوسان یا واگرایی در روند آموزش شود.

ث) الگوریتم Gradient Descent کلاسیک را با روش Adam مقایسه کرده و تفاوت های کلیدی آن ها را شرح دهید. مشخص کنید در چه شرایطی Adam عملکرد بهتری دارد و در عین حال یکی از ضعف های بالقوه این الگوریتم را توضیح دهید.

ج) چند روش عملی برای جلوگیری از بیش برآزش (Overfitting) در شبکه های عصبی ارائه کرده و کاربرد هر یک را توضیح دهید. همچنین بیان کنید که آیا افزایش تعداد نوروها در لایه های پنهان همیشه موجب بهبود عملکرد مدل می شود یا خیر. در نهایت، مکانیزم Dropout را معرفی کرده و مزایا و محدودیت های آن را بررسی نمایید.

چ) اگر مدل عملکرد مناسبی روی داده های آموزش اما نتایج ضعیفی روی داده های آزمایش داشته باشد، این نشانه چه رفتاری است؟ مفهوم Early Stopping را توضیح داده و شرح دهید چگونه از آن برای کنترل چنین رفتاری استفاده می شود. همچنین، در شرایطی که داده ها شامل نویز باشند، پیشنهاد دهید از کدام نوع تابع خطا استفاده شود و چرا.

۲. (۲۰ نمره) در مسئله ی رگرسیون سعی می شود رابطه تعدادی داده و برجسب آنها را مشخص شود. برای مثال اگر بدانیم بین جفت داده x_i, y_i یک رابطه درجه دو وجود داشته باشد سعی می شود در تابع زیر

$$\hat{y} = w_2 x^2 + w_1 x + w_0 \quad (1)$$

مقادیر w_0, w_1, w_2 به گونه ای پیدا شوند که مقدار تابع زیر کمینه شود.

$$f(w_2, w_1, w_0) = \sum_i (\hat{y}^i - y^i)^2 \quad (2)$$

در واقع $\hat{y}$ مقداری است که برای y پیش بینی می کنیم و تابع f میزان خطای این پیش بینی را نشان می دهد.

• تعریف R^2 اسکور را بنویسید و رابطه ی آن را با مجموع مربعات کل (SST) و مجموع مربعات باقیمانده (SSE) بیان کنید.

• توضیح دهید که چه زمانی R^2 به ۱ نزدیک می شود و چه زمانی ممکن است مقدار آن منفی شود.

- مقایسه‌ای بین MSE و R^2 انجام دهید و توضیح دهید در چه شرایطی ممکن است یک مدل MSE پایینی داشته باشد اما R^2 آن همچنان پایین باشد (یا برعکس).
- گرادینان تابع خطا را بیابید.
- رابطه Gradient Descent را برای تابع خطا تعیین کنید. با افزایش یا کاهش α در این رابطه چه اتفاقی می‌افتد؟

۳. (۲۵ نمره)

شرکتی در حوزه‌ی فناوری تصمیم دارد مدلی بسازد که بتواند بر اساس شرایط آب‌وهوا پیش‌بینی کند آیا کاربران در یک روز مشخص به فعالیت خارج از منزل تمایل خواهند داشت یا خیر. اطلاعات اولیه از نمونه‌های گذشته به شرح جدول زیر گردآوری شده است:

ردیف	Outlook	Temperature	Humidity	Wind	Activity
۱	Sunny	Hot	High	Weak	No
۲	Sunny	Hot	High	Strong	No
۳	Overcast	Hot	High	Weak	Yes
۴	Rain	Mild	High	Weak	Yes
۵	Rain	Cool	Normal	Weak	Yes
۶	Rain	Cool	Normal	Strong	No
۷	Overcast	Cool	Normal	Strong	Yes
۸	Sunny	Mild	High	Weak	No
۹	Sunny	Cool	Normal	Weak	Yes
۱۰	Rain	Mild	Normal	Weak	Yes
۱۱	Sunny	Mild	Normal	Strong	Yes
۱۲	Overcast	Mild	High	Strong	Yes
۱۳	Overcast	Hot	Normal	Weak	Yes
۱۴	Rain	Mild	High	Strong	No

الف) با شمارش مستقیم، تعیین کنید چند نمونه دارای برچسب Yes و چند نمونه دارای برچسب No هستند. سپس، با استفاده از رابطه زیر، میزان بی‌نظمی کل مجموعه را به دست آورید:

$$\text{Entropy}(S) = -p_+ \log_2(p_+) - p_- \log_2(p_-)$$

ب) ویژگی Outlook دارای سه مقدار ممکن است: Sunny، Overcast و Rain. برای هر یک از این سه دسته، ابتدا میزان Entropy زیرمجموعه را محاسبه کرده و در نهایت، مقدار Information Gain ناشی از استفاده از ویژگی Outlook در تقسیم‌بندی اول درخت را تعیین نمایید.

$$\text{Gain}(S, A) = \text{Entropy}(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} \cdot \text{Entropy}(S_v)$$

پ) محاسبه مشابه قسمت قبل را برای ویژگی‌های Temperature، Humidity و Wind نیز انجام دهید. در پایان، مشخص کنید کدام ویژگی در مرحله‌ی نخست بیشترین کاهش Entropy را ایجاد می‌کند و بنابراین بهترین گزینه برای گره ریشه درخت تصمیم است.

ت) با فرض انتخاب ویژگی بهینه به عنوان ریشه، ساختار سطح اول درخت تصمیم را ترسیم کنید. در صورت باقی ماندن بی نظمی (Entropy غیر صفر) در برخی شاخه‌ها، تعیین کنید کدام ویژگی برای تفکیک مرحله‌ی بعد مناسب‌تر خواهد بود.

ث) به پرسش‌های تحلیلی زیر در زمینه‌ی رفتار درخت تصمیم پاسخ دهید:

- در چه شرایطی ممکن است الگوریتم‌های درخت تصمیم دچار بیش‌برازش (Overfitting) شوند؟ یک نمونه‌ی فرضی ارائه دهید.
- دو روش برای کاهش خطر بیش‌برازش در درخت تصمیم را معرفی و تشریح کنید.
- در مواجهه با مجموعه داده‌ای پر از نویز، آیا الگوریتم ID3 انتخاب مناسبی برای مدل‌سازی است؟ دلایل خود را ذکر نمایید.

۴. (۲۰ نمره)

تابع زیر را در نظر بگیرید:

$$f(x_1, x_2) = \begin{cases} 3(x_1 - 1)^2 + 2(x_2 + 2)^2 + 1 & \text{اگر } x_1 + x_2 > 1 \\ \sin(x_1 x_2) & \text{در غیر این صورت} \end{cases}$$

- آ) یک شبکه عصبی با حداقل دو نورون مخفی طراحی کنید که بتواند این تابع را تقریب بزند. در طراحی خود از ساختار پایه نورون (وزن، بایاس، تابع فعال‌سازی) استفاده نمایید.
- ب) تعداد لایه‌ها و نورون‌ها، نوع تابع فعال‌سازی هر لایه، و دلایل انتخاب خود را به‌طور کامل توضیح دهید.

۵. (۲۰ نمره)

یک شبکه عصبی با معماری زیر در نظر بگیرید:

- ورودی: $x \in \mathbb{R}^3$
- لایه مخفی اول: ۴ نورون با تابع فعال‌سازی ReLU
- لایه مخفی دوم: ۲ نورون با تابع فعال‌سازی tanh
- خروجی: یک نورون با تابع فعال‌سازی sigmoid
- تابع هزینه: Binary Cross-Entropy

آ) ابعاد ماتریس‌های وزن و بایاس برای هر لایه را تعیین کنید.

ب) اگر بخواهیم این شبکه را برای m نمونه به صورت برداری (vectorized) پیاده‌سازی کنیم، ابعاد داده‌های ورودی و تمام ماتریس‌های میانی را بنویسید.

ج) با استفاده از قاعده زنجیره‌ای، مشتق نمادین $\frac{\partial J}{\partial W_1}$ را به‌دست آورید. مراحل را به‌صورت دقیق بنویسید.

د) با ذکر یک مثال عددی ساده، یک forward pass و backward pass برای این شبکه را محاسبه نمایید.