




فهرست مسائل

۱		مسئله ۱
۱		الف
۲		ب
۲		پ
۳		ت
۴		ث
۵		ج
۶		چ
۸		مسئله ۲
۸		الف
۸		ب
۹		ج
۹		د
۱۰		ه
۱۱		مسئله ۳
۱۱		الف
۱۱		ب
۱۱		پ
۱۳		ت
۱۴		ث
۱۵		مسئله ۴
۱۵		الف
۱۵		ب
۱۶		مسئله ۵
۱۶		الف
۱۶		ب
۱۶		ج
۱۷		د

پاسخ مسئله‌ی ۱.

الف




ویژگی	ReLU	سیگموئید
محدوده خروجی	$[0, +\infty)$	$(0, 1)$
تابع مشتق‌پذیر	خیر (در $x = 0$ ناپیوستگی دارد)	بله
مسئله ناپدید شدن گرادیان	ندارد یا بسیار کمتر	دارد
رفتار در نواحی منفی	خروجی صفر (امکان خاموشی نورون)	خروجی نزدیک به صفر

این شبکه دارای ۶ وزن و ۳ بایاس هست، پس جمعا دارای ۹ پارامتر قابل یادگیری هستیم.

ب

تابع ReLU به صورت زیر تعریف می‌شود:

$$\text{ReLU}(x) = \max(0, x)$$



همچنین اگر وزن‌ها طوری تنظیم شوند که ورودی نورون همیشه منفی باشد، ReLU همیشه صفر می‌شود و نورون دیگر هیچ‌وقت فعال نمی‌شود.

خروجی تابع ReLU برای ورودی -۲:

$$\text{ReLU}(-2) = \max(0, -2) = 0$$

پ

برای نورون اول:

$$z_1^{(1)} = w_{11}^{(1)}x_1 + w_{12}^{(1)}x_2 + b_1^{(1)} = 1 \times 1 + (-1) \times 1 + 0 = 0$$

$$a_1^{(1)} = \text{ReLU}(z_1^{(1)}) = \max(0, 0) = 0$$

برای نورون دوم:

$$z_2^{(1)} = w_{21}^{(1)}x_1 + w_{22}^{(1)}x_2 + b_2^{(1)} = 2 \times 1 + 1 \times 1 + 1 = 4$$

$$a_2^{(1)} = \text{ReLU}(z_2^{(1)}) = \max(0, 4) = 4$$

لایه خروجی:

$$y_{\text{pred}} = w_1^{(2)}a_1^{(1)} + w_2^{(2)}a_2^{(1)} + b^{(2)} = 2 \times 0 + (-1) \times 4 + 0 = -4$$

مقدار واقعی:

$$y = 5$$

تابع خطای میانگین مربعات:

$$\text{MSE} = \frac{1}{4}(y_{\text{pred}} - y)^2 = \frac{1}{4}(-4 - 5)^2 = \frac{1}{4}(81) = 40.5$$

ت

با استفاده از این فرمول‌ها، وزن‌ها را آپدیت می‌کنیم:

$$\Delta w_{ij} = \eta \delta_j o_i$$

$$\delta_j = f'(z_j) \cdot (t_j - o_j) \quad \text{output}$$

$$\delta_j = f'(z_j) \cdot \sum_k \delta_k w_{kj} \quad \text{hidden}$$

محاسبه δ برای نورون‌های خروجی

با توجه به استفاده از تابع هویت (مشتق برابر ۱):

$$\delta = t - o = 5 - (-4) = 9$$

برای نورون اول در لایه پنهان:

$$\Delta w_1^{(2)} = 0.1 \cdot 9 \cdot 0 = 0 \rightarrow w_1^{(2)} = 2 + 0 = 2$$

برای نورون دوم در لایه پنهان:

$$\Delta w_2^{(2)} = 0.1 \cdot 9 \cdot 4 = 3.6 \rightarrow w_2^{(2)} = -1 + 3.6 = 2.6$$

برای بایاس:

$$\Delta b^{(2)} = 0.1 \cdot 9 = 0.9 \rightarrow b^{(2)} = 0 + 0.9 = 0.9$$

محاسبه δ برای نورون‌های پنهان

مقادیر ورودی نورون‌های پنهان:

$$z_1^{(1)} = 0 \rightarrow f'(z_1) = 0, \quad z_2^{(1)} = 4 \rightarrow f'(z_2) = 1$$

برای نورون اول:

$$\delta_1^{(1)} = 0 \times 9 \times 2 = 0$$

برای نورون دوم:

$$\delta_2^{(1)} = 1 \times 9 \times (-1) = -9$$

نورون اول:

$$\delta_1 = 0 \rightarrow \Delta w_{11} = \Delta w_{12} = 0 \rightarrow \text{بدون تغییر}$$

نورون دوم:

$$\Delta w_{21} = 0.1 \times (-9) \times 1 = -0.9 \rightarrow w_{21} = 2 - 0.9 = 1.1$$

$$\Delta w_{22} = 0.1 \times (-9) \times 1 = -0.9 \rightarrow w_{22} = 1 - 0.9 = 0.1$$

$$\Delta b_2 = 0.1 \times (-9) = -0.9 \rightarrow b_2 = 1 - 0.9 = 0.1$$

نرخ یادگیری نقش تعیین کننده ای در به روزرسانی وزن ها دارد:

- اگر نرخ یادگیری بیش از حد کوچک باشد، آموزش بسیار کند پیش می رود و شبکه ممکن است در مینیمم محلی گیر کند.
- اگر نرخ یادگیری بیش از حد بزرگ باشد، به روزرسانی وزن ها بسیار شدید می شود و ممکن است باعث نوسان یا واگرایی در روند یادگیری شود.
- بنابراین، انتخاب مقدار مناسب برای η بسیار حیاتی است و معمولاً به کمک تجربه یا تنظیمات خودکار (مانند کاهش تطبیقی نرخ یادگیری) انجام می شود.

ث

الگوریتم Gradient Descent کلاسیک

- در این الگوریتم، پارامترها با استفاده از گرادیان کلی تابع هزینه نسبت به پارامترها، به روزرسانی می شوند:

$$\theta \leftarrow \theta - \eta \cdot \nabla_{\theta} J(\theta)$$

- نیاز به انتخاب یک نرخ یادگیری ثابت دارد.
- ممکن است در دره های باریک یا سطوح پرنوسان کند پیش برود یا گیر کند.

الگوریتم Adam (Adaptive Moment Estimation)

- Adam از دو مفهوم استفاده می کند:

۱. میانگین گرادیان ها (momentum) – مانند سرعت حرکت.

۲. میانگین مربعات گرادیان ها (RMS) – کنترل نوسان.

- فرمول های اصلی:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} J(\theta)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} J(\theta))^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta \leftarrow \theta - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

تفاوت‌های کلیدی بین Adam و Gradient Descent

- **نرخ یادگیری:** در Gradient Descent نرخ یادگیری یک مقدار ثابت است و نیاز به تنظیم دقیق دارد، در حالی که Adam نرخ یادگیری را به صورت تطبیقی برای هر پارامتر تنظیم می‌کند.
- **سرعت همگرایی:** Gradient Descent معمولاً کندتر همگرا می‌شود، به‌خصوص در فضاهای با توپوگرافی پیچیده؛ در مقابل، Adam با استفاده از مومنتوم و میانگین مربعات گرادیان، سریع‌تر به جواب می‌رسد.
- **حساسیت به مقیاس داده‌ها:** Gradient Descent نسبت به مقیاس داده‌ها حساس است و اغلب نیاز به نرمال‌سازی دارد، در حالی که Adam این مسئله را با نرمال‌سازی درونی کاهش می‌دهد.
- **نیاز به تنظیمات دستی:** در Gradient Descent انتخاب نرخ یادگیری حیاتی است و به تنظیم دقیق نیاز دارد؛ ولی Adam اغلب با مقادیر پیش‌فرض (مثل $\beta_1 = 0.9$ و $\beta_2 = 0.999$) به خوبی کار می‌کند.
- **مصرف حافظه:** Gradient Descent حافظه بسیار کمی مصرف می‌کند؛ اما Adam برای هر پارامتر دو متغیر (میانگین و واریانس گرادیان) ذخیره می‌کند و نیاز به حافظه بیشتری دارد.

مزایا و شرایط مناسب استفاده از Adam

- مناسب برای مسائل با داده‌های بزرگ، ویژگی‌های زیاد یا نویز بالا.
- عملکرد خوب بدون نیاز به تنظیم زیاد هاپرپارامترها.
- مناسب برای شبکه‌های عمیق مانند CNN و RNN.

ضعف بالقوه Adam

- گاهی در نزدیکی مینیمم بهینه عمومی (Global-Minima) نمی‌رسد.
- به‌روزرسانی‌ها ممکن است ناپایدار شوند در صورتی که داده‌ها کاملاً نرمال‌سازی نشده باشند.
- در برخی مسائل ساده، GD یا SGD بهتر عمل می‌کنند.

ج

۱. استفاده از داده‌افزایی (Data-Augmentation)

در مسائل بینایی ماشین، با چرخش، کشیدن، برش، نویزگذاری یا فلیپ کردن تصاویر می‌توان حجم داده‌ها را افزایش داد و مدل را از یادگیری جزئیات خاص داده‌ها بازداشت.

۲. تنظیم وزن‌ها (Weight-Regularization)

با استفاده از جریمه‌هایی مانند L_1 و L_2 روی وزن‌ها، از بزرگ شدن بیش از حد وزن‌ها جلوگیری شده و مدل ساده‌تری ساخته می‌شود:

$$\text{Loss} = \text{MSE} + \lambda \sum_i w_i^2$$

۳. توقف زودهنگام (Early-Stopping)

مدل در هنگام آموزش به محض افزایش خطای اعتبارسنجی (Validation) متوقف می‌شود، تا از بیش‌برازش جلوگیری شود.

۴. کاهش پیچیدگی مدل

با کاهش تعداد لایه‌ها یا تعداد نوروها در هر لایه، ظرفیت مدل کاهش می‌یابد و از یادگیری نویز جلوگیری می‌شود.

آیا افزایش تعداد نوروهای پنهان همیشه مفید است؟

خیر. افزایش بیش از حد نوروها در لایه‌های پنهان باعث افزایش ظرفیت مدل و خطر بیش‌برازش می‌شود. در حالی که ممکن است دقت روی داده‌های آموزشی بالا برود، عملکرد مدل روی داده‌های جدید (تست) کاهش می‌یابد.

مکانیزم Dropout

تعریف: Dropout تکنیکی است که در هر مرحله از آموزش، به‌طور تصادفی برخی نوروها (و وزن‌های متصل به آن‌ها) غیرفعال می‌شوند.

مزایا:

- جلوگیری از وابستگی بیش از حد به نوروهای خاص
- نوعی ensemble ساده‌سازی‌شده از مدل‌های مختلف ایجاد می‌کند
- بهبود تعمیم‌پذیری (generalization)

محدودیت‌ها:

- ممکن است سرعت همگرایی را کاهش دهد
- نیاز به تنظیم دقیق نرخ dropout دارد
- گاهی در شبکه‌های بازگشتی (RNN) باعث بی‌ثباتی در حافظه زمانی می‌شود

چ

اگر مدل روی داده‌های آموزش عملکرد خوبی دارد اما روی داده‌های آزمایش (تست) نتایج ضعیفی ارائه می‌دهد، این نشانه‌ای از بیش‌برازش (Overfitting) است. در این حالت، مدل به‌جای یادگیری الگوهای کلی، جزئیات خاص و نویزهای داده‌های آموزش را یاد گرفته و قابلیت تعمیم‌دهی به داده‌های جدید را از دست داده است.

مفهوم Early Stopping

Early-Stopping تکنیکی برای جلوگیری از بیش‌برازش است که در آن فرآیند آموزش مدل در صورت افزایش خطای اعتبارسنجی (validation-error) متوقف می‌شود. ایده اصلی آن است که مدل را در نقطه‌ای متوقف کنیم که بهترین عملکرد را روی داده‌های اعتبارسنجی داشته باشد، نه الزاماً در پایان تمامی epoch ها.

- در هر epoch ، مدل روی مجموعه اعتبارسنجی ارزیابی می‌شود.
- اگر بهبود معناداری در خطای اعتبارسنجی طی چند دوره مشاهده نشود، آموزش متوقف می‌شود.
- وزنهایی که در بهترین عملکرد ثبت شده‌اند، به عنوان مدل نهایی در نظر گرفته می‌شوند.

انتخاب تابع خطا در داده‌های دارای نویز

در حضور نویز یا داده‌های پرت (outliers) ، استفاده از تابع خطای MSE توصیه نمی‌شود، چرا که:

- MSE مجذور خطا را در نظر می‌گیرد و به خطاهای بزرگ وزن بیشتری می‌دهد.
- داده‌های پرت تأثیر زیادی بر به‌روزرسانی وزن‌ها دارند.

پیشنهاد: استفاده از توابع مقاوم‌تر مانند:

- MAE (Mean Absolute Error): به خطاهای بزرگ حساس نیست و در برابر نویز مقاوم‌تر است.
- Huber Loss: ترکیبی از MSE و MAE است؛ برای خطاهای کوچک مانند MSE عمل می‌کند و برای خطاهای بزرگ مانند MAE.

پاسخ مسئله‌ی ۲.

الف

R^2 یا ضریب تعیین، معیاری برای سنجش کیفیت برازش مدل رگرسیون است و نشان می‌دهد که چه نسبتی از واریانس کل خروجی‌ها توسط مدل توضیح داده شده است.

فرمول محاسبه آن به صورت زیر است:

$$R^2 = 1 - \frac{SSE}{SST}$$

که در آن:

$$SSE = \sum_i (y^i - \hat{y}^i)^2 \quad \bullet \quad \text{مجموع مربعات باقی‌مانده یا خطاها (Sum of Squared Errors)}$$

$$SST = \sum_i (y^i - \bar{y})^2 \quad \bullet \quad \text{مجموع مربعات کل (Total Sum of Squares)}$$

در نتیجه، R^2 به ما می‌گوید که مدل چه سهمی از کل تغییرات داده‌ها را توانسته با پیش‌بینی‌هایش پوشش دهد.

ب

- مقدار R^2 به ۱ نزدیک می‌شود زمانی که مدل رگرسیون بتواند تغییرات خروجی‌های واقعی را به‌خوبی پیش‌بینی کند. در این حالت، مقدار SSE بسیار کوچک می‌شود و تقریباً تمام واریانس موجود در داده‌ها توسط مدل توضیح داده می‌شود:

$$R^2 \approx 1 \quad \Leftrightarrow \quad SSE \ll SST$$

- مقدار R^2 ممکن است منفی شود اگر مدل بسیار ضعیف عمل کند و پیش‌بینی‌های آن از پیش‌بینی ساده میانگین $\bar{y}$ نیز بدتر باشد. این یعنی:

$$SSE > SST \quad \Rightarrow \quad R^2 < 0$$

این حالت معمولاً زمانی رخ می‌دهد که مدل اشتباه انتخاب شده باشد یا یادگیری مدل به‌درستی انجام نشده باشد.

ج

مقایسه مفهومی:

- MSE (میانگین مربعات خطا) نشان‌دهنده مقدار میانگین خطای مدل در واحد اندازه‌گیری خروجی است. مقدار آن همیشه مثبت است و هرچه کمتر باشد، بهتر.
- R^2 مقیاسی نسبی است که عملکرد مدل را نسبت به یک مدل ساده (که همیشه میانگین $\bar{y}$ را پیش‌بینی می‌کند) مقایسه می‌کند. این مقدار می‌تواند مثبت یا منفی باشد.

وضعیت تضاد:

- ممکن است یک مدل مقدار MSE پایینی داشته باشد، ولی مقدار R^2 آن پایین یا حتی منفی باشد، در صورتی که:
- مقادیر واقعی y^i تغییرات بسیار کمی داشته باشند (یعنی SST بسیار کوچک باشد).
 - در این حالت حتی خطای کوچک مدل (مقدار SSE نسبتاً کوچک) نیز ممکن است از SST بزرگ‌تر باشد و R^2 را منفی کند.

مثال معکوس:

- همچنین ممکن است مقدار R^2 نسبتاً بالا باشد ولی مقدار MSE بزرگ باشد؛ این زمانی رخ می‌دهد که:
- داده‌های واقعی y^i دامنه تغییرات بزرگی داشته باشند (یعنی SST بسیار بزرگ باشد)، در نتیجه حتی اگر SSE نیز بزرگ باشد، نسبت $\frac{SSE}{SST}$ کوچک باقی بماند و R^2 عدد بزرگی شود.

د

برای به‌دست آوردن گرادیان، باید مشتق جزئی تابع خطا را نسبت به هر پارامتر بگیریم.

گرادیان نسبت به w_2 :

$$\frac{\partial f}{\partial w_2} = \sum_i 2 (\hat{y}^i - y^i) \cdot (x^i)^2$$

گرادیان نسبت به w_1 :

$$\frac{\partial f}{\partial w_1} = \sum_i 2 (\hat{y}^i - y^i) \cdot x^i$$

گرادیان نسبت به w_0 :

$$\frac{\partial f}{\partial w_0} = \sum_i 2 (\hat{y}^i - y^i)$$

۵

در روش Gradient Descent، پارامترهای مدل به صورت تکراری به سمت خلاف جهت گرادیان تابع خطا به روزرسانی می‌شوند تا مقدار تابع خطا کاهش یابد. رابطه کلی به شکل زیر است:

$$\theta \leftarrow \theta - \alpha \cdot \nabla_{\theta} f(\theta)$$

که در آن:

- θ نمایانگر پارامترهای مدل (مثلاً w_1, w_2, w) است.
- $\nabla_{\theta} f(\theta)$ گرادیان تابع خطا نسبت به θ است.
- α نرخ یادگیری است.

تأثیر تغییر α :

- اگر α خیلی کوچک باشد: به روزرسانی پارامترها کند انجام می‌شود و همگرایی مدل بسیار آهسته خواهد بود.
- اگر α خیلی بزرگ باشد: به روزرسانی‌ها بیش از حد شدید شده و ممکن است مدل از نقطه بهینه عبور کند یا دچار نوسان و واگرایی شود.
- انتخاب مناسب α : نرخ یادگیری باید به اندازه‌ای باشد که مدل سریع و پایدار به سمت کمینه تابع خطا حرکت کند.

پاسخ مسئله‌ی ۳.

الف

محاسبه Entropy کل:

$$Entropy(S) = -\left(\frac{9}{14} \log_2 \frac{9}{14} + \frac{5}{14} \log_2 \frac{5}{14}\right) \approx 0.414 + 0.529 = 0.940$$

ب

• ویژگی Outlook دارای سه مقدار است: Rain ، Overcast ، Sunny

۱. Outlook = Sunny

$$Entropy(Sunny) = -\left(\frac{2}{5} \log_2 \frac{2}{5} + \frac{3}{5} \log_2 \frac{3}{5}\right) \approx 0.528 + 0.442 = 0.971$$

۲. Outlook = Overcast

$$Entropy(Overcast) = -\left(\frac{4}{4} \log_2 \frac{4}{4} + \frac{0}{4} \log_2 \frac{0}{4}\right) = 0 + 0 = 0$$

۳. Outlook = Rain

$$Entropy(Rain) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5}\right) \approx 0.442 + 0.528 = 0.971$$

محاسبه Information-Gain برای Outlook :

$$Gain(S, Outlook) = Entropy(S) - \left(\frac{5}{14} \times 0.971 + \frac{4}{14} \times 0 + \frac{5}{14} \times 0.971\right) = 0.940 - 0.694 = 0.246$$

پ

• ویژگی Temperature دارای سه مقدار است: Hot ، Mild ، Cool

۱. Temperature = Hot

$$Entropy(Hot) = -\left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4}\right) = 1$$

۲. Temperature = Mild

$$Entropy(Mild) = -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) \approx 0.918$$

۳. Temperature = Cool

$$Entropy(Cool) = -\left(\frac{3}{4} \log_2 \frac{3}{4} + \frac{1}{4} \log_2 \frac{1}{4}\right) \approx 0.811$$

محاسبه Information-Gain برای Temperature :

$$Gain(S, Temperature) = Entropy(S) - \left(\frac{4}{14} \times 1 + \frac{6}{14} \times 0.918 + \frac{4}{14} \times 0.811 \right) = 0.029$$

• ویژگی Humidity دارای دو مقدار است: Normal ، High

۱. Humidity = High

$$Entropy(High) = -\left(\frac{4}{7} \log_2 \frac{4}{7} + \frac{3}{7} \log_2 \frac{3}{7} \right) \approx 0.985$$

۲. Humidity = Normal

$$Entropy(Normal) = -\left(\frac{6}{7} \log_2 \frac{6}{7} + \frac{1}{7} \log_2 \frac{1}{7} \right) \approx 0.592$$

محاسبه Information-Gain برای Humidity :

$$Gain(S, Humidity) = Entropy(S) - \left(\frac{7}{14} \times 0.985 + \frac{7}{14} \times 0.592 \right) = 0.151$$

• ویژگی Wind دارای دو مقدار است: Strong ، Weak

۱. Wind = Weak

$$Entropy(Weak) = -\left(\frac{2}{8} \log_2 \frac{2}{8} + \frac{6}{8} \log_2 \frac{6}{8} \right) \approx 0.811$$

۲. Wind = Strong


$$Entropy(Strong) = -\left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6} \right) = 1$$

محاسبه Information-Gain برای Wind :

$$Gain(S, Wind) = Entropy(S) - \left(\frac{8}{14} \times 0.811 + \frac{6}{14} \times 1 \right) = 0.048$$

نتیجه: ویژگی Outlook بهترین انتخاب برای گره ریشه است.

ت



شاخه‌های sunny و rain دارای آنتروپی غیر صفر هستند. پس یک سطح دیگر نیاز است درخت را در این شاخه‌ها ادامه دهیم و سپس بررسی کنیم.

• مرحله دوم شاخه sunny :

$$Entropy(Sunny) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5}\right) \approx 0.971$$

$$Gain(Humidity) = 0.971 - \left(\frac{3}{5} \times 0 + \frac{2}{5} \times 0\right) = 0.971$$


در این حالت Gain ما با Entropy اولیه برابر شده، پس ویژگی Humidity را انتخاب می‌کنیم.

• مرحله دوم شاخه Rain :

$$Entropy(Rain) = -\left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5}\right) \approx 0.971$$

$$Gain(Wind) = 0.971 - \left(\frac{3}{5} \times 0 + \frac{2}{5} \times 0\right) = 0.971$$

در این حالت Gain ما با Entropy اولیه برابر شده، پس ویژگی Wind را انتخاب می‌کنیم.




ث

- وقتی مدل تصمیم‌گیری بیش از حد به جزئیات داده‌های آموزش وفادار باشد. مثلاً: استفاده از ویژگی‌های کم‌ارزش یا نادر برای جدا کردن نمونه‌ها.
- حذف شاخه‌هایی که اطلاعات زیادی به مدل نمی‌دهند. (Pruning) تقسیم داده‌ها برای ارزیابی عملکرد مدل روی داده‌های ندیده‌شده. (Cross-validation)
- خیر. چون ID^۳ به شدت به داده‌های آموزشی وابسته است و نمی‌تواند با داده‌های نویزی یا ناقص به خوبی کنار بیاید. الگوریتم‌هایی مثل Random-Forest مقاوم‌تر هستند.

پاسخ مسئله‌ی ۴.

الف

ساختار شبکه عصبی طراحی شده به این صورت است:



ب

نورون N_{14} برای ما مکانیزم تصمیم‌گیری را انجام می‌دهد. به این صورت که از تابع سیگموید استفاده شده است. در نورون‌های بالایی تابع چند جمله‌ای و سینوسی را ساخته‌ام. برای تابع چند جمله‌ای ما ورودی‌ها را جمع و به توان دو می‌رسانیم و به راحتی تابع Activation مورد نیاز ساخته می‌شود. اما برای ساخت Sin نیاز است تا یک تریک معروف را انجام دهیم و از Tanh دو لایه استفاده کنیم. در نهایت شبکه عصبی ما دارای ۵ لایه (ورودی + ۳ لایه میانی و ۱ لایه خروجی) است.

پاسخ مسئله‌ی ۵.

الف

$$\begin{aligned}
input &\in R^{\mathfrak{r}} \\
output_1 &\in R^{\mathfrak{f}} \quad output_2 \in R^{\mathfrak{r}} \quad output_3 \in R^1 \\
w_1 &\in R^{\mathfrak{f} \times \mathfrak{r}} \quad w_2 \in R^{\mathfrak{r} \times \mathfrak{f}} \quad w_3 \in R^{1 \times \mathfrak{r}} \\
b_1 &\in R^{\mathfrak{f} \times 1} \quad b_2 \in R^{\mathfrak{r} \times 1} \quad b_3 \in R^{1 \times 1}
\end{aligned}$$

ب

$$x \in R^{\mathfrak{r} \times m}$$

• لایه اول

$$\begin{aligned}
z_1 &= w_1 x + b_1 \in R^{\mathfrak{f} \times m} \\
a_1 &= Relu(z_1) \in R^{\mathfrak{f} \times m}
\end{aligned}$$

• لایه دوم

$$\begin{aligned}
z_2 &= w_2 a_1 + b_2 \in R^{\mathfrak{r} \times m} \\
a_2 &= \tanh(z_2) \in R^{\mathfrak{r} \times m}
\end{aligned}$$

• لایه خروجی

$$\begin{aligned}
z_3 &= w_3 a_2 + b_3 \in R^{1 \times m} \\
\hat{y} &= \sigma(z_3) \in R^{1 \times m}
\end{aligned}$$

ج

فرمول تابع هزینه به صورت زیر است:

$$J = \frac{-1}{m} \sum_{i=1}^m (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

با توجه به قاعده زنجیره، مشتق تابع هزینه نسبت به وزن لایه اول به صورت زیر محاسبه می‌شود:

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial z_3} \cdot \frac{\partial z_3}{\partial a_2} \cdot \frac{\partial a_2}{\partial z_2} \cdot \frac{\partial z_2}{\partial a_1} \cdot \frac{\partial a_1}{\partial z_1} \cdot \frac{\partial z_1}{\partial w_1}$$

$$\begin{aligned}
\frac{\partial J}{\partial z_3} &= \frac{1}{m} (\hat{y} - y) \in R^{1 \times m} \\
\frac{\partial J}{\partial w_3} &= \frac{1}{m} (\hat{y} - y) \cdot a_2^T \in R^{1 \times \mathfrak{r}}
\end{aligned}$$

$$\begin{aligned}
\frac{\partial J}{\partial A_2} &= w_3^T \cdot \frac{1}{m} (\hat{y} - y) \in R^{\mathfrak{r} \times m} \\
\frac{\partial J}{\partial z_2} &= \frac{\partial J}{\partial A_2} \odot (1 - \tanh^2(z_2)) \in R^{\mathfrak{r} \times m} \\
\frac{\partial J}{\partial w_2} &= \frac{1}{m} \left(\frac{\partial J}{\partial z_2} \cdot a_1^T \right) \in R^{\mathfrak{r} \times \mathfrak{f}}
\end{aligned}$$

$$\begin{aligned}
\frac{\partial J}{\partial A_1} &= w_2^T \cdot \frac{\partial J}{\partial z_2} \in R^{\mathfrak{f} \times m} \\
\frac{\partial J}{\partial z_1} &= \frac{\partial J}{\partial A_1} \odot \left(\frac{d}{dz} Relu(z_1) \right) \in R^{\mathfrak{f} \times m} \\
\frac{\partial J}{\partial w_1} &= \frac{1}{m} \frac{\partial J}{\partial z_1} x^T \in R^{\mathfrak{f} \times \mathfrak{r}}
\end{aligned}$$

د

محاسبه Forward Pass:

$$x = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad m = 1$$

$$z_1 = w_1 x + b_1 = \begin{bmatrix} 1 & 0 & -1 \\ 2 & -1 & 0 \\ 0 & 1 & 1 \\ -1 & -2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1(1) + 0(2) + (-1)(3) \\ 2(1) - 1(2) + 0(3) \\ 0(1) + 1(2) + 1(3) \\ -1(1) - 2(2) + 1(3) \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \\ 1 \\ 4 \\ -2 \end{bmatrix}$$

$$a_1 = \text{ReLU}(z_1) = \begin{bmatrix} 0 \\ 1 \\ 4 \\ 0 \end{bmatrix}$$

$$z_2 = w_2 a_1 + b_2 = \begin{bmatrix} 1 & -1 & 0 & 2 \\ 0 & 1 & -1 & -1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 4 \\ 0 \end{bmatrix} = \begin{bmatrix} (1)(0) + (-1)(1) + (0)(4) + (2)(0) \\ (0)(0) + (1)(1) + (-1)(4) + (-1)(0) \end{bmatrix} = \begin{bmatrix} -1 \\ -3 \end{bmatrix}$$

$$a_2 = \tanh(z_2) = \begin{bmatrix} \tanh(-1) \\ \tanh(-3) \end{bmatrix} \approx \begin{bmatrix} -0.76 \\ -0.995 \end{bmatrix}$$

$$z_3 = w_3 a_2 + b_3 = \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} -0.76 \\ -0.995 \end{bmatrix} = (-0.76) - (-0.995) = 0.235$$

$$\hat{y} = \sigma(z_3) = \frac{1}{1 + e^{-0.235}} \approx 0.5585$$

محاسبه Backward Pass:

$$\frac{\partial J}{\partial z_3} = \hat{y} - y = 0.5585 - 1 = -0.4415$$

$$\frac{\partial J}{\partial w_2} = \frac{1}{m} \cdot (\hat{y} - y) \cdot a_1^T = (-0.4415) \cdot \begin{bmatrix} -0.76 & -0.995 \end{bmatrix} = \begin{bmatrix} 0.3355 & 0.4393 \end{bmatrix}$$

$$\frac{\partial J}{\partial b_2} = \frac{\partial J}{\partial z_2} = -0.4415$$

$$\frac{\partial J}{\partial a_1} = w_2^T \cdot \frac{\partial J}{\partial z_2} = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \cdot (-0.4415) = \begin{bmatrix} -0.4415 \\ 0.4415 \end{bmatrix}$$

$$\frac{\partial J}{\partial z_1} = \frac{\partial J}{\partial a_1} \odot (1 - \tanh^2(z_2)) \approx \begin{bmatrix} -0.4415 \\ 0.4415 \end{bmatrix} \odot \begin{bmatrix} 1 - 0.5776 \\ 1 - 0.9900 \end{bmatrix} = \begin{bmatrix} -0.4415 \cdot 0.4224 \\ 0.4415 \cdot 0.01 \end{bmatrix} = \begin{bmatrix} -0.1865 \\ 0.0044 \end{bmatrix}$$

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial z_1} \cdot a_1^T = \begin{bmatrix} -0.1865 \\ 0.0044 \end{bmatrix} \begin{bmatrix} 0 & 1 & 4 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -0.1865 & -0.746 & 0 \\ 0 & 0.0044 & 0.0176 & 0 \end{bmatrix}$$

$$\frac{\partial J}{\partial b_1} = \frac{\partial J}{\partial z_1} = \begin{bmatrix} -0.1865 \\ 0.0044 \end{bmatrix}$$

$$\frac{\partial J}{\partial a_1} = w_1^T \cdot \frac{\partial J}{\partial z_1} = \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \\ 2 & -1 \end{bmatrix} \cdot \begin{bmatrix} -0/1865 \\ 0/1909 \\ 0/0044 \end{bmatrix} = \begin{bmatrix} -0/1865 \\ 0/1909 \\ -0/0044 \\ -0/3774 \end{bmatrix}$$

$$\frac{\partial J}{\partial z_1} = \frac{\partial J}{\partial a_1} \odot \text{ReLU}'(z_1) = \begin{bmatrix} 0 \\ 0/1909 \\ -0/0044 \\ 0 \end{bmatrix}$$

$$\frac{\partial J}{\partial w_1} = \frac{\partial J}{\partial z_1} \cdot x^T = \begin{bmatrix} 0 \\ 0/1909 \\ -0/0044 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0/1909 & 0/3818 & 0/5727 \\ -0/0044 & -0/0088 & -0/0132 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\frac{\partial J}{\partial b_1} = \frac{\partial J}{\partial z_1} = \begin{bmatrix} 0 \\ 0/1909 \\ -0/0044 \\ 0 \end{bmatrix}$$